Fakultet elektrotehnike, računarstva i informacijskih tehnologija Osijek

Računarstvo usluga i analiza podataka

SEMINARSKI RAD

Predviđanje tipa osobnosti

Božidar Kelić,

Nikola Ramčić

Osijek, 2026.

Sadržaj

1. Uvod 1
2. Opis problema 2
2.1 Korišteni podaci 2
2.2 Korišteni postupci strojnoga učenja 4
3. Opis programskog rješenja 6
3.1 Model strojnog učenja 7
3.2 Način korištenja API-a 11
3.3 Klijentska aplikacija 13
4. Zaključak 17
5. Literatura 18

1. Uvod

Razlike u načinu na koji se ljudi ponašaju u društvenim situacijama oduvijek su bile predmet interesa psihologije i društvenih znanosti. Neki se pojedinci osjećaju energično u većim skupinama i rado sudjeluju u razgovorima, dok drugi preferiraju mirnije okruženje i manji broj bliskih kontakata. Takve razlike utječu na način komunikacije, radne navike, donošenje odluka te općenito svakodnevno funkcioniranje.

Cilj ovog rada je prikazati razvoj sustava koji na temelju dostupnih atributa klasificira ispitanike u dvije skupine: one koji pokazuju izraženiju usmjerenost prema društvenim interakcijama (ekstrovert) i one koji preferiraju povučeniji stil funkcioniranja (introvert). Cijeli proces se oslanja na *Azure Machine Learning* platformu koja omogućava rad sustava u oblaku te brzo obrađivanje podataka.

2. Opis problema

Problem klasifikacije ponašanja na temelju zadanih atributa predstavlja tipičan zadatak nadziranog učenja s binarnom ciljnom varijablom [0 ili 1]. U ovom slučaju cilj je na temelju različitih pokazatelja društvenih navika i preferencija, predvidjeti pripada li pojedinac skupini s naglašenijom društvenom otvorenošću (ekstroverti) ili skupini koja preferira manji intenzitet socijalnih interakcija (introverti).

Tradicionalne metode procjene osobnosti obično se oslanjaju na opsežne psihološke upitnike i stručnu analizu, što može biti dugotrajno i zamorno. U istraživačkom kontekstu, ovaj skup podataka služi kao referentni primjer za evaluaciju klasifikacijskih algoritama na području društvene analitike. Korištenjem automatiziranih modela strojnoga učenja otvara se mogućnost brze identifikacije ključnih osobina na temelju svakodnevnih navika, što ovaj problem čini iznimno relevantnim za primijenjenu psihologiju i analizu podataka.

Iako je na ovakvim skupovima podataka često moguće postići visoku točnost primjenom kompleksnih algoritama, takvi modeli često postaju "crne kutije" čije je odluke teško interpretirati. U praksi, modeli poput ovoga mogu poslužiti kao pomoćni alati za procjenu sklonosti određenom tipu osobnosti, no važno je naglasiti da oni ne zamjenjuju stručnu psihološku dijagnozu.

Cilj ovog rada usmjeren je na istraživanje mogućnosti postizanja visoke točnosti klasifikacije koristeći ograničen broj lako mjerljivih ponašajnih pokazatelja, uz pritom jednostavne i interpretabilne modele strojnog učenja.

2.1 Korišteni podaci

U ovom radu korišten je skup podataka pod nazivom *Extrovert vs. Introvert Behavior Data*, koji je dostupan putem Kaggle platforme (izvorno postavio korisnik Rakesh Kapilavayi)[1]. Ovaj skup podataka prikupljen je s ciljem istraživanja korelacije između svakodnevnih navika pojedinca i njegovog tipa osobnosti. Skup obuhvaća različite bihevioralne aspekte, poput socijalne interakcije, prisutnosti na društvenim mrežama i razine energije u društvenom kontekstu, kako bi se omogućilo precizno razlikovanje između introverata i ekstroverata.

Skup podataka sastoji se od oko 2.900 zapisa (unosa) koji opisuju ispitanike putem 8 ključnih značajki, dok je ciljna varijabla (label) kategorizirana kao "Introvert" ili "Extrovert". Uvidom u distribuciju podataka na slici 1, vidljivo je da su klase uravnotežene te nije potrebno raditi rebalansiranje uzoraka.

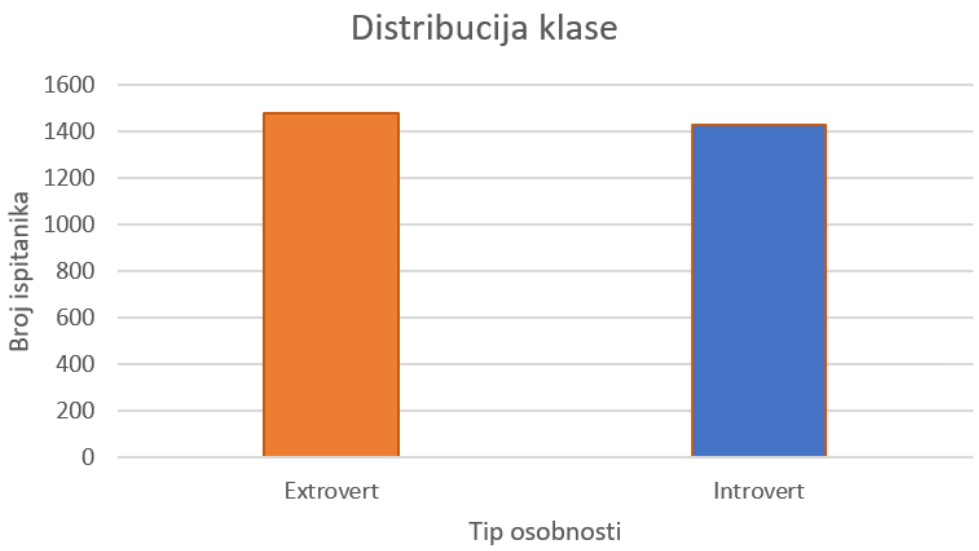

Slika 1. Prikaz tipa osobnosti u skupu podataka

Skup podataka definiran je numerički i kategoričkim vrijednostima. Neke od značajki su vrijeme provedeno u samoći, učestalost posjećivanja društvenih događanja, učestalost izlazaka, strah od javnog nastupa, osjećaj iscrpljenosti nakon druženja, veličina kruga prijatelja, te učestalost objava na društvenim mrežama. Značajke su detaljnije opisane u tablici 1.

Značajka	**Moguća vrijednost**	**Opis**
Time_spent_Alone	Cijeli broj (0–11 sati dnevno)	Broj sati dnevno koje osoba provede sama, bez društva drugih ljudi.
Stage_fear	Yes, No	Označava ima li osoba strah od javnog nastupa ili govora pred publikom.
Social_event_attendance	Cijeli broj (0–10)	Učestalost sudjelovanja na društvenim događajima (zabave, okupljanja, eventi) u zadanom razdoblju.
Going_outside	Cijeli broj (0–7)	Učestalost odlazaka iz kuće radi neobaveznih, društvenih ili rekreativnih aktivnosti.
Drained_after_socializing	Yes, No	Označava osjeća li se osoba mentalno ili emocionalno iscrpljeno nakon druženja s drugim ljudima.
Friends_circle_size	Cijeli broj (0–15)	Broj bliskih prijatelja u užem krugu osobe.
Post_frequency	Cijeli broj (0–10)	Učestalost objava na društvenim mrežama u tjednu
Personality	Introvert, Extrovert	Ciljna varijabla koja označava procijenjeni tip ličnosti osobe (introvert ili ekstrovert).

Tablica 1. Prikaz značajki u skupu podataka

Prikaz prvih 5 podataka iz podatkovnog skupa prikazan je na tablici 2.

	Time_spent_Alone	Stage_fear	Social_event_attendance	Going_outside	Drained_after_socializing	Friends_circle_size	Post_frequency	Personality
1.	2	No	8	6	No	12	9	Extrovert
2.	7	Yes	2	1	Yes	3	1	Introvert
3.	3	No	7	5	No	10	7	Extrovert
4.	8	Yes	1	1	Yes	2	0	Introvert
5.	5	No	4	3	Yes	6	3	Introvert

Tablica 2. Prikaz prvih pet podatkovnih primjera

2.2 Korišteni postupci strojnoga učenja

Prije samog strojnog učenja napravljena je EDA (Eksplorativna analiza podataka). Sve vrijednosti su pretvorene u numeričke, nepopunjeni uzorci su uklonjeni, a prije same implementacije modela testirali smo pet različitih algoritama strojnoga učenja. Sljedeći algoritmi pokazali su najbolje rezultate:

- **Two-class boosted decision tree** - Pojačano stablo odlučivanja za dvije klase. Kombinira više jednostavnih stabala odlučivanja u niz (engl. boosting) kako bi postupno ispravljao pogreške i poboljšao točnost klasifikacije između dvije moguće klase [2].
- **Two-class decision forest** - Šuma odlučivanja za dvije klase. Sastoji se od velikog broja stabala odlučivanja koja zajedno donose odluku (glasanjem). Vrlo je robusna metoda za klasifikaciju u dvije kategorije.
- **Two-class logistic regression** - Logistička regresija za dvije klase. Statistički model koji procjenjuje vjerojatnost pripadnosti jednoj od dvije klase koristeći logističku funkciju.
- **Two-class support vector machines (SVM)** -Stroj potpornih vektora za dvije klase. Algoritam koji pronalazi optimalnu granicu (hiperravninu) koja najbolje razdvaja dvije klase podataka.
- **Two-class neural network** - Neuronska mreža za dvije klase. Model inspiriran radom ljudskoga mozga koji uči obrasce iz podataka i koristi ih za klasifikaciju u jednu od dvije kategorije.

Kako bi smo povećali točnost te smanjili pretjerano prilagođavanje podacima (engl. Overfitting) raspodijelili smo 70% podataka za učenje te 30% za testiranje. Primjenom unakrsne provjere (engl. K Fold cross validation) optimizacijskog postupka, rezultati nisu mnogo odstupali od obične raspodjele.

3. Opis programskog rješenja

U ovom poglavlju prikazan je opis programskog rješenja razvijenog u okviru projekta. Objašnjava se arhitektura sustava, korištene tehnologije te način međusobne komunikacije pojedinih komponenti aplikacije. Prikazana je implementacija modela strojnog učenja, povezivanje putem REST API-ja, razvoj klijentske web aplikacije te integraciju baze podataka i modula za vizualizaciju. Cilj poglavlja je pružiti jasan pregled tehničke realizacije sustava i načina na koji su teorijski koncepti primijenjeni u praktičnom rješenju.

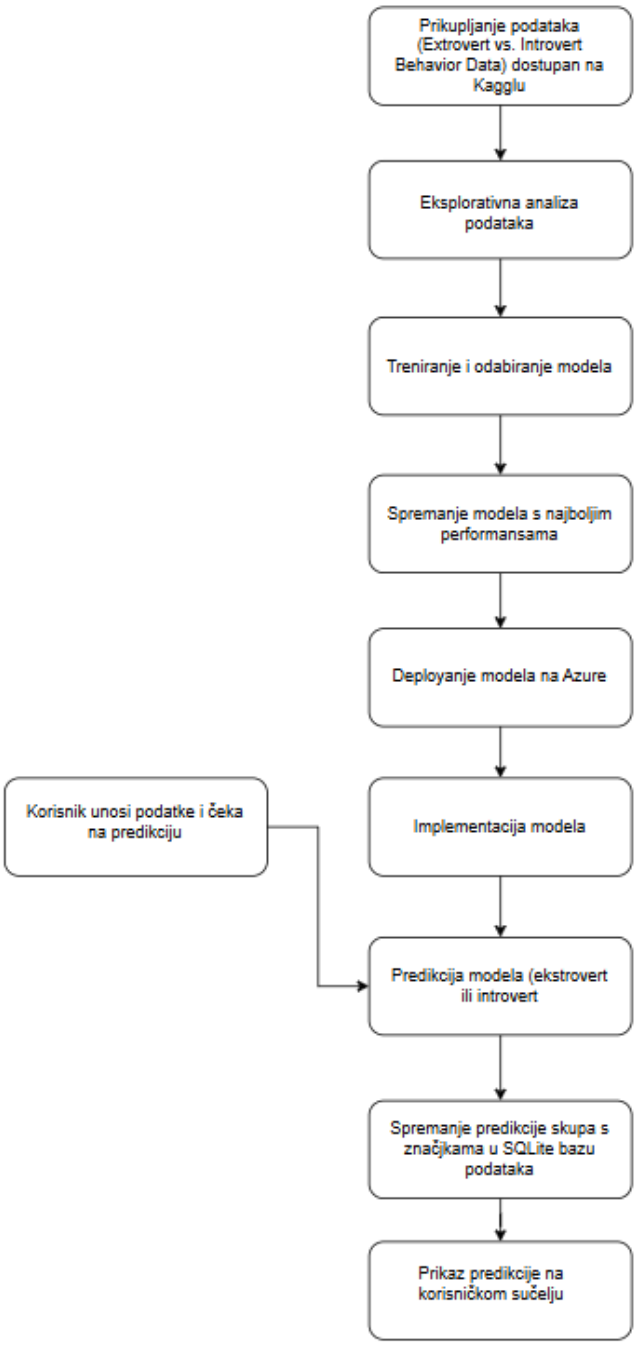

Slika 1. Dijagram toka programskog rješenja

3.1 Model strojnog učenja

Za odabir najboljeg modela korišten je servis *Azure AutoML* koji je automatski ispitao više algoritama i kombinirao različite hiperparametre, te ih je usporedio prema odabranoj metrici točnosti. Nakon što su identificirani modeli s najboljim rezultatima, oni su implementirani u *okruženju Azure Machine Learning Studia*, gdje je napravljena detaljna usporedba njihovih točnosti prikazanih na slici 3.

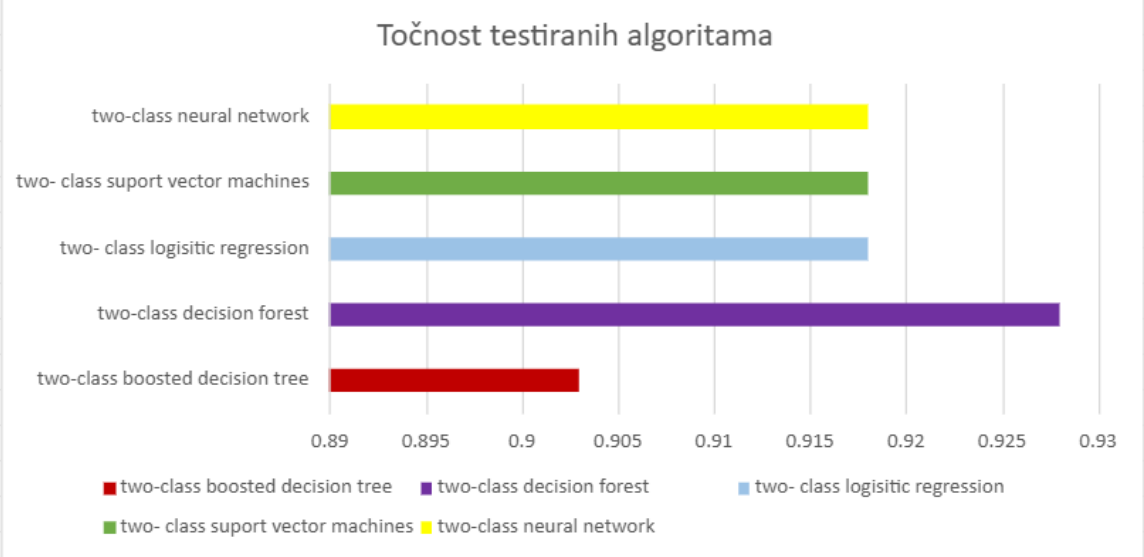

Slika 3. Prikaz točnosti testiranih modela

Na slici 3 vidljivo je da je najvišu vrijednost odabrane metrike postigao algoritam *Two-Class Decision Forest*, za konfiguraciju hiperparametara prikazanu na slici 4, zbog čega je odabran kao konačni model za daljnju implementaciju. Implementacija *Two-Class Decision Fo*rest modela u obliku cjevovoda (engl. pipelinea) provedena je pomoću *Azure ML Designera*, što je prikazano na slici 5.

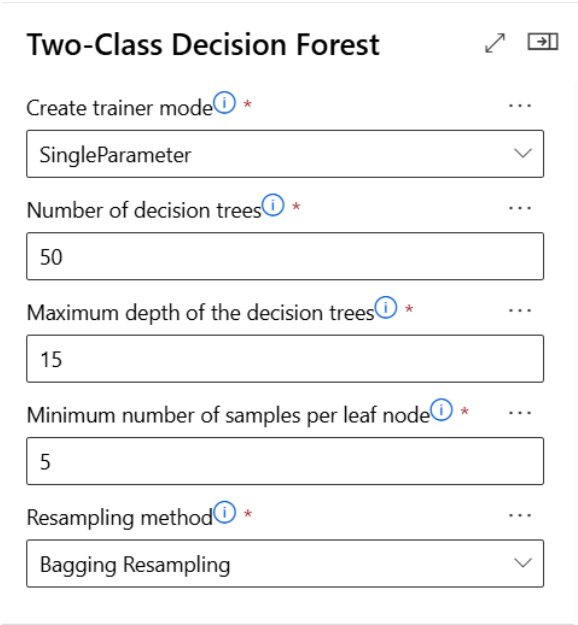

Slika 4. Prikaz hiperparametara modela

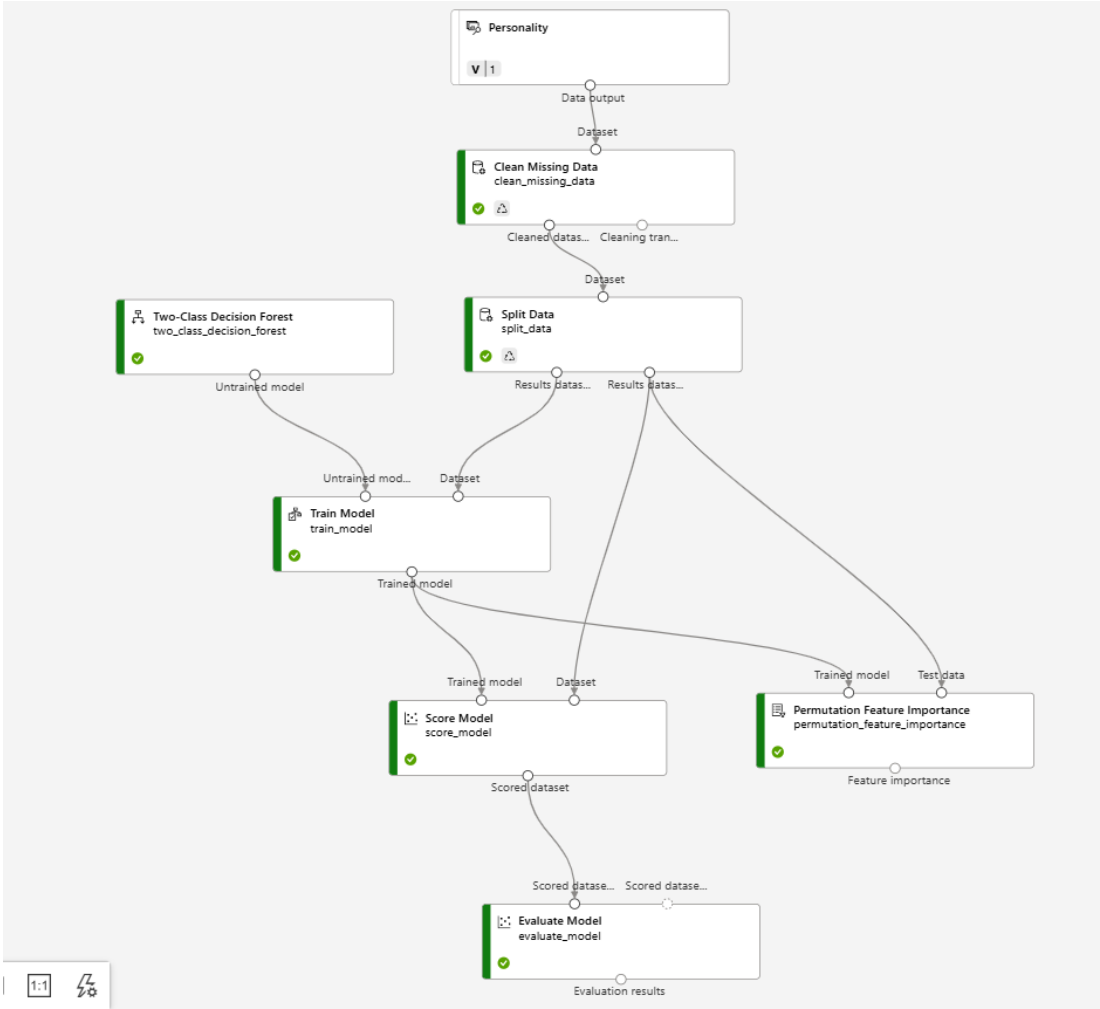

Slika 5. Prikaz cjevovoda

Postupak izrade cjevovoda započinje unošenjem (tj. učitavanjem) skupa podataka, nakon čega slijedi modul „Clean Missing Data“, kojim se uklanjaju ili nadopunjuju nedostajuće vrijednosti kako bi se osigurala kvaliteta i konzistentnost podataka. Budući da je kao konačni model odabran *algoritam Two-Class Decision Forest*, normalizacija podataka nije primijenjena, jer ovaj tip stablastog modela nije osjetljiv na različite skale ulaznih značajki [3].

Tako pripremljeni podaci prosljeđuju se u modul „Split Data“, gdje se skup dijeli na trening i testni dio u omjeru 70:30, čime se omogućuje objektivna evaluacija modela. Na trening dio podataka povezuje se algoritam *Two-Class Decision Forest*, koji se u modulu „Train Model“ trenira nad označenom ciljnom varijablom. Nakon treniranja, model se primjenjuje na testne podatke kroz modul „Score Model“, gdje se generiraju predikcije. Dobiveni rezultati zatim se analiziraju u modulu „Evaluate Model“, koji prikazuje metrike uspješnosti poput matrice zabune, točnosti, preciznosti, odziva i AUC vrijednosti. Prikaz metrike uspješnosti za model s *Two-Class Decision Forest* algoritmoxxm vidljiv je na slici 6.

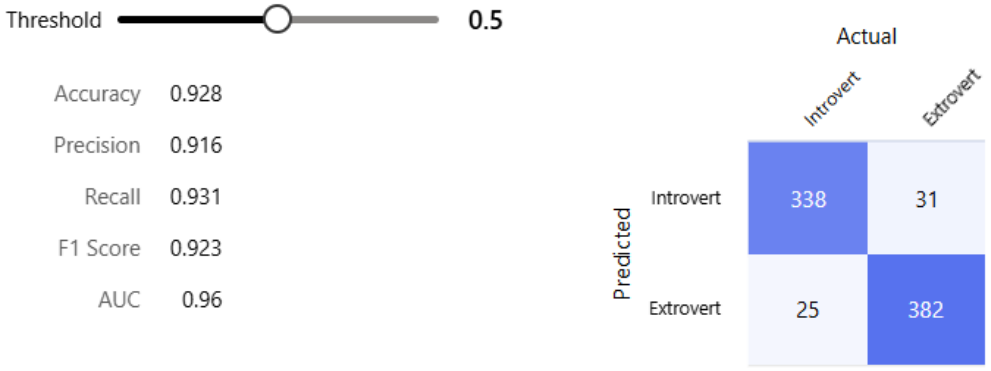

Slika 6. Prikaz metrike uspješnosti (lijevo) te matrice zabune (desno)

Prema metrici uspješnosti vidimo iz „Accuracy-a“ da model gotovo 93% uzoraka ispravno klasificira, te da je mal udio lažno pozitivnih predikcija (Precision - 1) * 100. Također iz AUC-a vidimo da model odlično razdvaja klase kroz različite pragove odlučivanja. Iz matrice zabune vidljivo je da je model ispravno klasificirao 338 introverata i 328 ekstroverata, dok je 25 introverata pogrešno svrstao u klasu ekstroverata, a 31 ekstroverta pogrešno u klasu introverata. Sveukupno, dobivene metrike ukazuju na to da model postiže vrlo dobre performanse i pouzdanu točnost klasifikacije.

PersonalityPrediction	Probability
Extrovert	0.046193
Introvert	0.910749
Introvert	0.951059

Slika 7. Prikaz metrike uspješnosti (lijevo) te matrice zabune (desno)

Za testiranje predikcije modela koristili smo modul „Execute Pythone Script“ za ručno unošenje podataka. Testirana su tri primjera unosa podataka, a slika 7 prikazuje rezultate koji su dobiveni nakon obrade unesenih podataka. Iz rezultata vidimo da je model s popriličnom sigurnošću utvrdio da je prva osoba ekstrovert, a preostale dvije Introvert. Navedeno je vidljivo iz vjerojatnosti koja je definirana prema pragu (engl. tresholdu) vidljivom na slici 6. Što je model bliže nuli to je sigurniji da je osoba ekstrovert, a u suprotnom što je bliže jedinici to je sigurniji da je introvert.

Modul „Permutation Feature Importance“, korišten je za procjenu važnost pojedinih značajki za konačnu odluku modela. Pomoću navedenog modula se dobiva uvid u to koji atributi najviše doprinose klasifikaciji te se po potrebi može provesti daljnja redukcija značajki radi pojednostavljenja modela. Prikaz rezultata prethodno opisanog modula vidljiv je na slici 8.

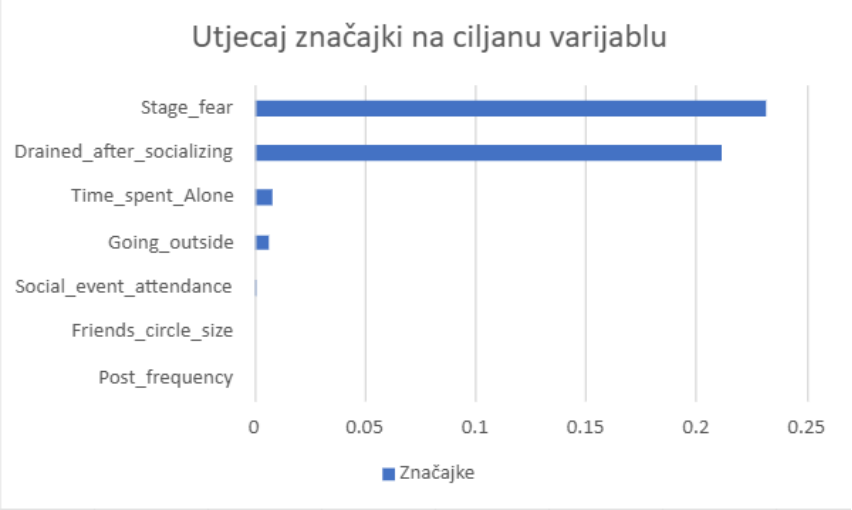

Slika 8. Rangiranje značajki prema vrijednosti na ciljanu varijablu

Iz slike 8. vidimo da model u najvećoj mjeri donosi odluku na temelju informacija vezanih uz nelagodu pri javnom nastupu te osjećaj iscrpljenosti nakon društvenih interakcija. Znatno manji, ali ipak prisutan utjecaj ima vrijeme koje je ispitanik proveo sam te koliko često izlazi van. Ostale značajke ne nose značajnu dodatnu informaciju za model jer je njihova informativnost već "uhvaćena" kroz jače značajke.

3.2 Način korištenja API-a

API je baziran na REST arhitekturi, shodno tome koristi HTTP protokol za obradu zahtjeva. API je realiziran kao web servis pomoću *Azure Machine Learning Studia.*

U tablici 3. prikazani su podaci koji se šalju ili primaju kada se poziva krajnja točka realizirana pomoću *Azure Machine Learning Studia.* Krajnja točka se poziva pomoću POST zahtjeva na njezinu adresu. Tip sadržaja šalje se u zaglavlju. U tijelu zahtjeva navodi se JSON objekt koji sadrži sve potrebne stupce za obavljanje predviđanja. Kao odgovor dobiva se kojoj vrsti osobnosti pripada ispitanik i vjerojatnost preciznosti same klasifikacije. Za predane podatke iz tablice 3 model predviđa da je osoba ekstrovert.

Karakteristika	Vrijednost
Adresa krajnje točke	http://1d80b764-3a0a-4c2c-b5a6-353e66c7ac64.polandcentral.azurecontainer.io/score
Metoda	POST
Zaglavlje	'Content-Type':'application/json'

Tijelo zahtjeva	data = {
	"Inputs": {
	"input1": [
	{
	"Time_spent_Alone": 4,
	"Stage_fear": "No",
	"Social_event_attendance": 4,
	"Going_outside": 6,
	"Drained_after_socializing": "No",
	"Friends_circle_size": 13,
	"Post_frequency": 5
	},
	]
	},
	"GlobalParameters": {}
	}

Tijelo odziva	{
	"Results": {
	"WebServiceOutput0": [
	{
	"PersonalityPrediction": "Extrovert",
	"Probability": 0.04619309558391309}]
	}
	}
	}

Dodatno, sustav je proširen integracijom lokalne SQLite baze podataka, implementirane kao „file-based" rješenje koje ne zahtijeva zaseban poslužitelj. Kada korisnik putem sučelja odabere željene značajke i pokrene proces predikcije, frontend aplikacija šalje HTTP zahtjev prema Azure REST API krajnjoj točki. Nakon obrade podataka, Azure servis vraća rezultat klasifikacije koji se potom pohranjuje u lokalnu SQLite bazu. Ovakav pristup omogućuje trajno spremanje svih korisničkih unosa i dobivenih rezultata bez potrebe za kompleksnom infrastrukturom baze podataka.

Poseban naglasak stavljen je na vizualizaciju prikupljenih podataka. Svakim novim unosom automatski se generira ažurirani vizualni prikaz spremljenih rezultata. Iako je osnovna svrha aplikacije klasifikacija osobnosti, sustav je nadograđen modulom za dugoročno praćenje i analizu podataka. Prilikom svakog pokretanja analize, odabrane značajke i dobivena klasifikacija pohranjuju se u SQLite bazu podataka, čime se omogućuje naknadna obrada i statistička analiza.

Za manipulaciju i obradu podataka koristili smo dobro poznatu biblioteku Pandas [4], koja omogućuje pretvaranje zapisa iz baze u strukturirane tablične prikaze za daljnju analizu. Vizualizacija podataka realizirana je pomoću biblioteke Plotly Express, koja omogućuje izradu interaktivnih grafova.

3.3 Klijentska aplikacija

Početna stranica klijentske aplikacije predstavlja glavno sučelje koje povezuje korisnika s modelom strojnog učenja implementiranim u *Azure Machine Learning* okruženju. Nakon pokretanja aplikacije korisniku se prikazuje uvodna stranica prikazana na slici 9, osmišljena u obliku informativnog članka kao one-side-page [5] . Njezin je cilj postupno uvesti korisnika u temu osobnosti kroz objašnjenje osnovnih psiholoških pojmova te prikaz najvažnijih karakteristika introvertnog i ekstrovertnog tipa osobnosti tj. ličnosti.

Stranica sadrži pregledno strukturiran tekst koji opisuje razlike između tipova osobnosti, njihove tipične obrasce ponašanja i način funkcioniranja u društvenim situacijama. Osim edukativne uloge, početna stranica ima i interaktivnu funkciju jer korisniku omogućuje pokretanje analize vlastite osobnosti. Putem jasno istaknutog gumba korisnik može pristupiti obrascu za unos podataka, nakon čega aplikacija koristi model strojnog učenja s Azura, kako bi procijenila pripada li korisnik introvertnom ili ekstrovertnom tipu osobnosti.

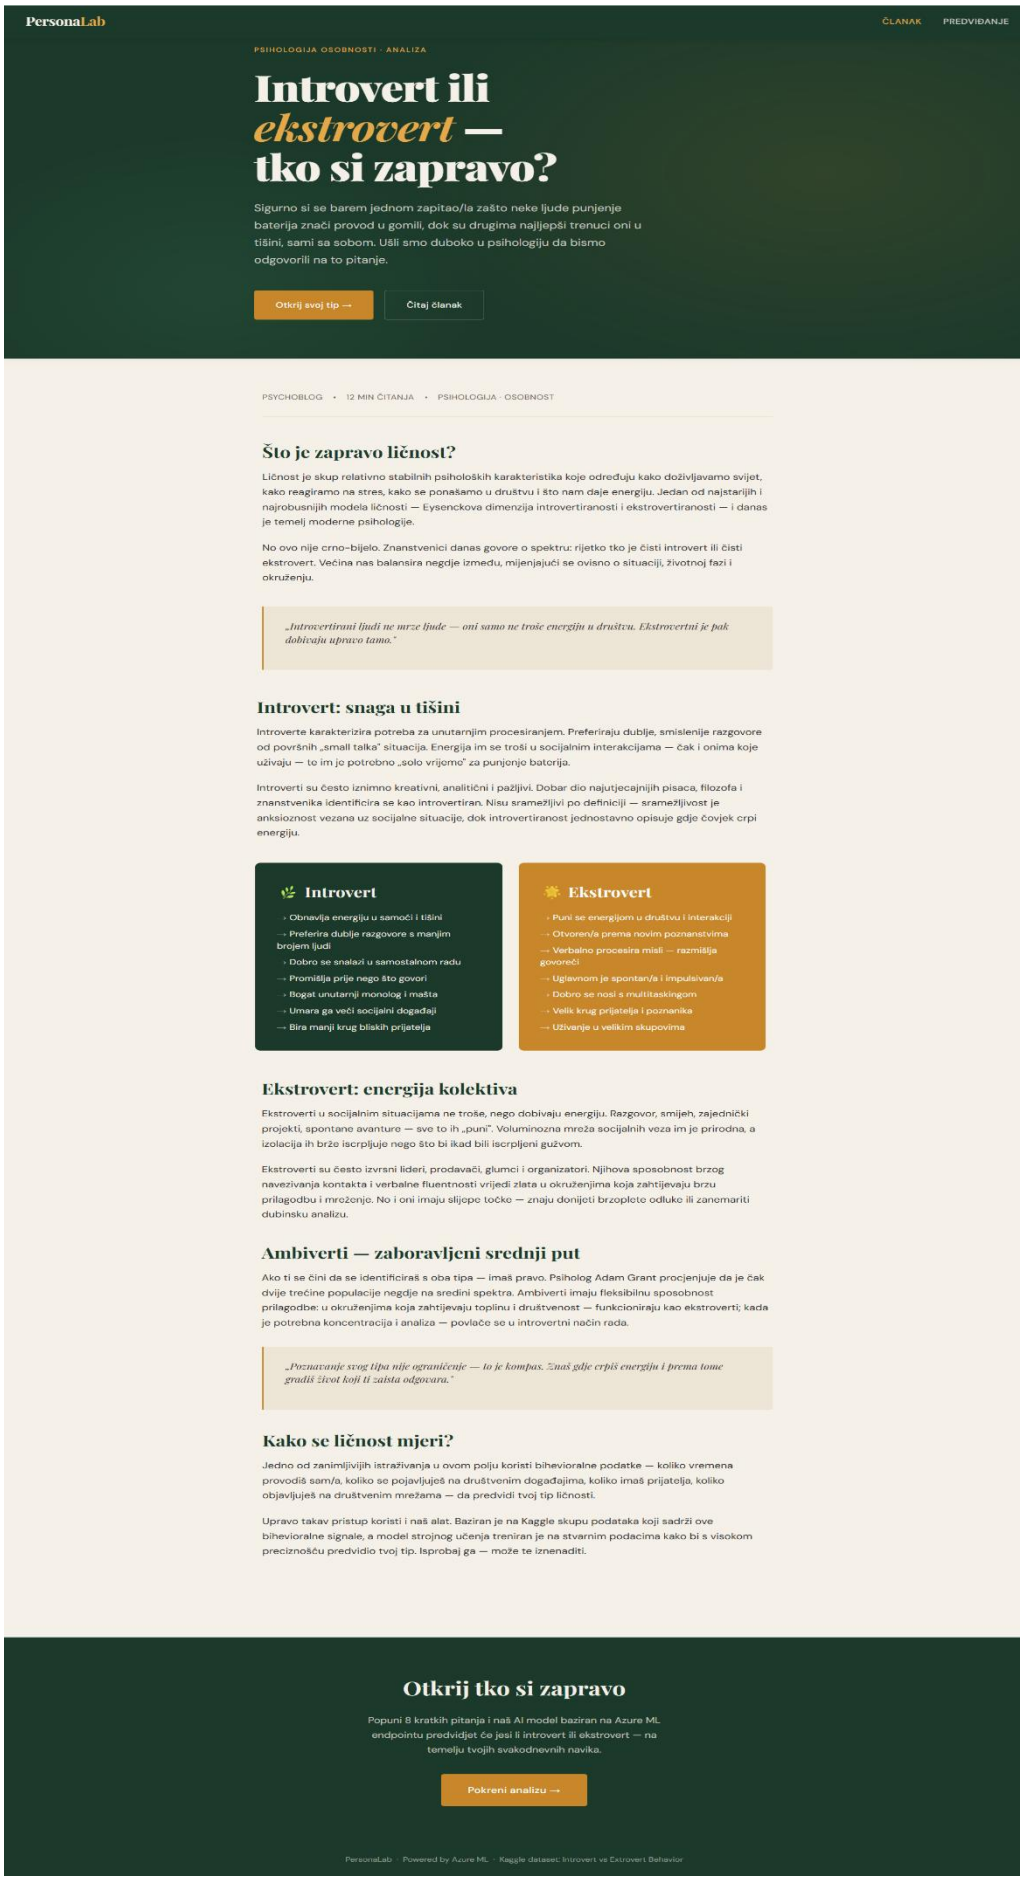

Slika 9. Prikaz cijele početne stranice web aplikacije

Prilikom odabira otkrivana vlastitog tipa osobnosti otvara se stranica prikazana na slici 10. koja predstavlja stranicu za analizu osobnosti. Stranica omogućuje korisniku unos podataka potrebnih za predikciju tipa osobnosti pomoću modela strojnog učenja. Na lijevom dijelu nalazi se interaktivni obrazac s nizom kontrola poput klizača i odabirnih gumba, putem kojih korisnik unosi informacije o svojim navikama i socijalnom ponašanju. Unosi obuhvaćaju: prosječno vrijeme provedeno nasamo, učestalost društvenih događaja i izlazaka, razinu straha od javnog nastupa, osjećaj iscrpljenosti nakon socijalizacije, veličinu kruga bliskih prijatelja te učestalost objava na društvenim mrežama. Nakon popunjavanja svih polja, korisnik pokreće analizu pritiskom na jasno označen gumb za otkrivanje tipa osobnosti.

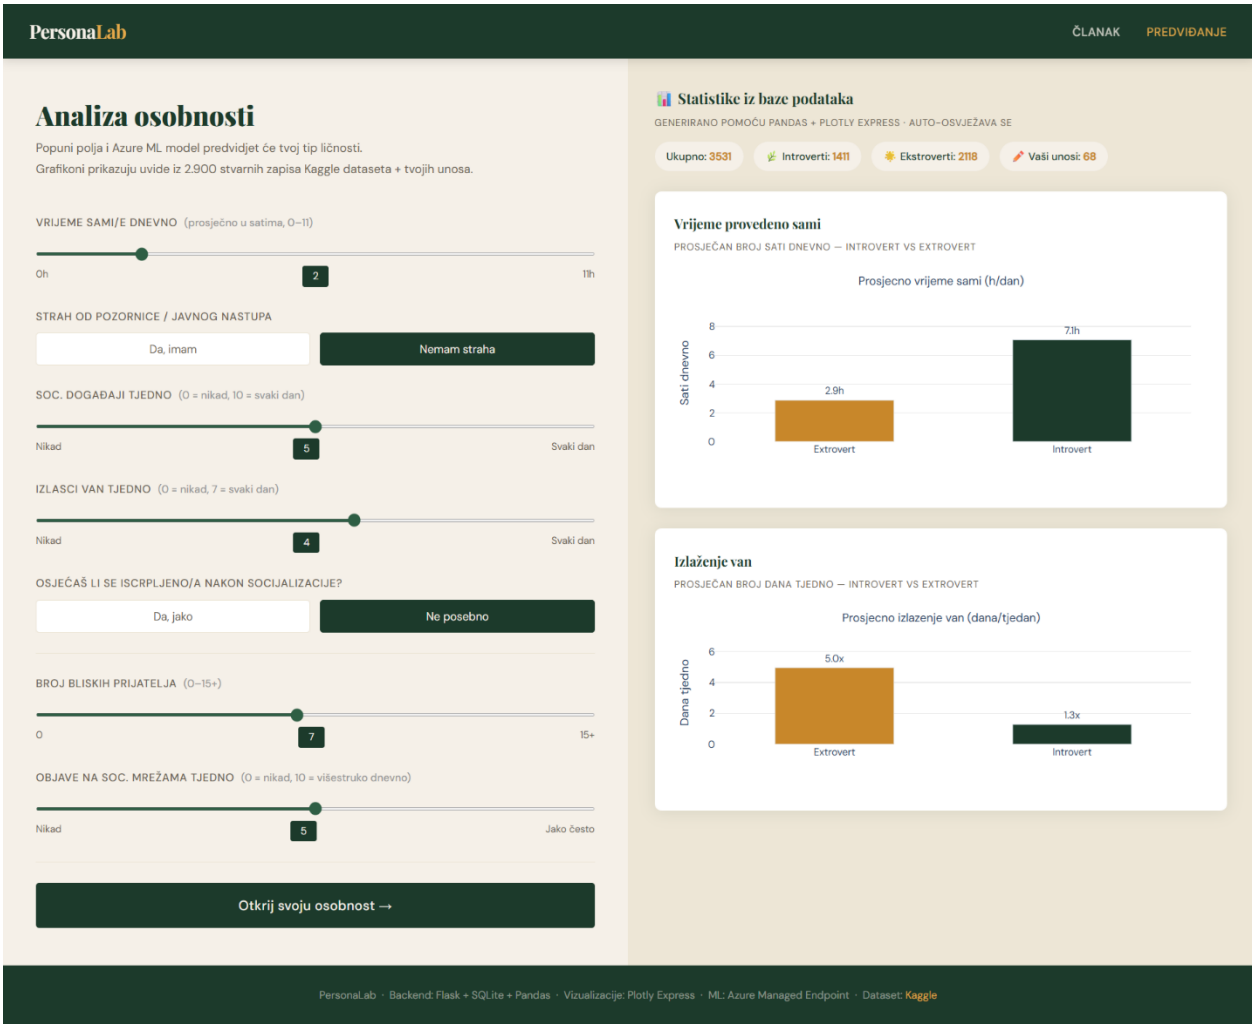

Slika 10. Prikaz stranice za analizu osobnosti

Desna dio stranice služi za prikaz uvida dobivenih iz SQLite baze podataka na kojoj je model treniran. Prikazane su informacije poput: ukupnog broja zapisa, broja introvertnih i ekstrovertnih ispitanika te broja korisničkih unosa prikupljenih putem aplikacije. Uz navedeno, vizualizirani su i grafički prikazi koji uspoređuju prosječne vrijednosti pojedinih ponašanja između tipova osobnosti, kao što su prosječno

vrijeme provedeno nasamo ili učestalost izlazaka. Na taj način stranica istovremeno pruža funkcionalnost unosa podataka za predikciju i edukativni uvid u obrasce ponašanja karakteristične za različite tipove osobnosti.

Ovisno o ulaznim podacima model klasificira ulazne značajke u jedno od dvije osobnosti koje su prikazane na slici 11. to jest, prikazuje pripada li osoba skupini ekstroverta ili introverta .

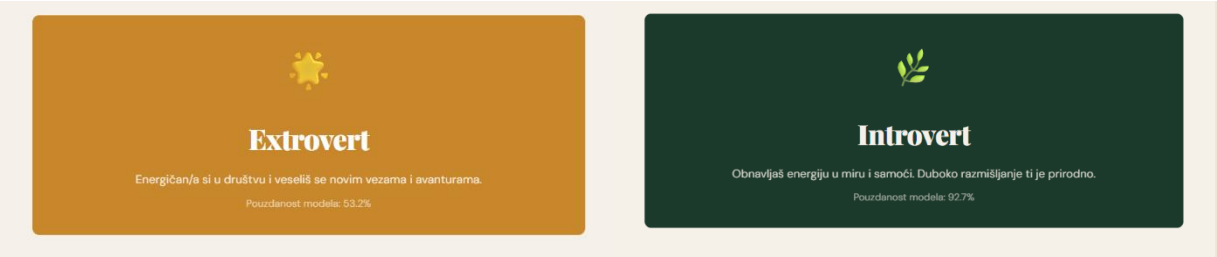

Slika 11. Prikaz izlaza predikcije modela

4. Zaključak

Zaključno, u okviru ovog projekta razvijena je cjelovita aplikacija za predviđanje tipa osobnosti koja objedinjuje elemente strojnog učenja, obrade podataka i web razvoja. Model je treniran u okruženju *Azure Machine Learninga* na stvarnim podacima te je implementiran kao mrežni servis kojemu klijentska aplikacija pristupa putem REST API-ja.

Dodatna vrijednost sustava ostvarena je integracijom lokalne SQLite baze podataka, koja je implementirana kao jednostavno „file-based" rješenje bez potrebe za zasebnim poslužiteljem. Nakon što korisnik unese odabrane značajke i pokrene predikciju, aplikacija šalje HTTP zahtjev prema Azure REST API-ju, a dobiveni rezultat klasifikacije automatski se pohranjuje u bazu. Na taj način omogućeno je trajno spremanje svih korisničkih unosa i rezultata, čime sustav dobiva i komponentu dugoročnog prikupljanja podataka.

Poseban naglasak stavljen je i na vizualizaciju prikupljenih podataka. Svakim novim unosom automatski se ažurira grafički prikaz spremljenih rezultata, što korisnicima omogućuje lakše razumijevanje obrazaca i trendova. Za obradu podataka korištena je biblioteka Pandas, koja omogućuje učinkovito pretvaranje zapisa iz baze u strukturirane tablične prikaze, dok je vizualizacija realizirana pomoću Plotly Expressa, čime su dobiveni interaktivni i pregledni grafovi vidljivi na slici 10.

Projekt je omogućio stjecanje praktičnih znanja iz područja pripreme podataka, treniranja i evaluacije modela, implementacije strojnog učenja u oblaku, rada s REST API-jima te razvoja jednostavne web aplikacije. Time je demonstrirana primjena pristupa koji povezuje računarstvo, analizu podataka i suvremene tehnologije umjetne inteligencije.

5. Literatura

Programsko rješenje: https://github.com/Boki147/RUAP-pojekt

[1] - https://www.kaggle.com/datasets/rakeshkapilavai/extrovert-vs-introvert-behavior-data/data

[2] T. Hastie, R. Tibshirani, and J. Friedman. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed., Springer, 2009.

[3] - https://learn.microsoft.com/en-us/azure/machine-learning/component-reference/two-class-decision-forest?view=azureml-api-2

[4] - https://pandas.pydata.org/docs/

[5] - https://www.seobility.net/en/wiki/One_Pager